

MVP – Construção de Pipeline de Dados na Nuvem

Autor: Helena Ann Pereira

Matricula: 4052026000265

Tema: Comportamento de vendas de uma operação de chocolates

Plataforma: Databricks Free Edition (Unity Catalog, Delta Lake, PySpark e SQL)

Base de dados: [Chocolate Sales Data](#) — Kaggle

1. Contexto de Negócios e Perguntas

1.1. Contexto do problema

O trabalho parte do cenário de uma operação de venda de chocolates que atua em múltiplos países por meio de uma equipe de vendedores. A definição do problema precedeu a busca pelos dados e o problema de negócio formulado foi: entender o comportamento de vendas dessa operação e identificar os fatores que afetam a receita a partir do estudo de quais produtos sustentam o faturamento, como a receita se distribui no tempo e se existe concentração em poucos itens, vendedores ou mercados.

1.2. Perguntas de negócio

- Quais produtos geram maior receita e quais geram maior volume de caixas? São os mesmos?
- Como a receita se distribui ao longo dos meses do período coberto?
- O preço médio por caixa varia entre países?
- Os vendedores de maior receita vendem mais volume ou vendem produtos mais caros?
- Existe concentração de receita em poucos produtos ou vendedores?

Todas as perguntas foram mantidas integralmente no escopo original, inclusive aquelas que não puderam ser respondidas.

1.3. Estrutura dos dados brutos

A fonte é um arquivo único em formato CSV, com 14 kB, 1.094 registros e 6 colunas. Cada linha corresponde a uma venda.

Coluna de Origem	Conteúdo	Formato original
Sales Person	Nome do vendedor responsável	Texto (25 valores distintos)
Country	País onde a venda ocorreu	Texto (6 valores distintos)
Product	Nome do produto de chocolate	Texto (22 valores distintos)
Date	Data da venda	Texto no padrão 'dd-MMM-yy'
Amount	Valor total da venda	Texto com cifrão e separador de milhar
Boxes Shipped	Quantidade de caixas expedidas	Texto numérico

O arquivo não possui identificador único de transação, nem campos de custo, desconto, canal de venda ou cliente e o período coberto é de **03/01/2022 a 31/08/2022**.

1.4. Licença de uso

A base está publicada no Kaggle sob **licença MIT**, que permite uso, modificação e redistribuição, inclusive para fins acadêmicos, mediante manutenção do aviso de licença. Não há restrição ao uso acadêmico.

- **Fonte:** Chocolate Sales Data, de Atharva Soundankar


- **Endereço:** <https://www.kaggle.com/datasets/atharvasoundankar/chocolate-sales?resource=download>

A descrição publicada pelo autor declara que os dados foram agregados a partir de varejistas e marketplaces.

2. Carga dos Dados

A coleta foi feita por upload direto do arquivo para a plataforma de nuvem, caminho adequado dado que a fonte é um arquivo estático de tamanho reduzido e já disponível em formato tabular.

Foi feito o download do arquivo “Chocolate Sales.csv” disponível no Kaggle (posteriormente renomeado para “chocolate_sales.csv” evitando problemas causados pelo espaço no nome. Em seguida, foi feita a criação dos 3 Schemas da Arquitetura Medalhão e de um Volume no Unity Catalog, onde foi feito o Upload do arquivo por meio do Catalog Explorer, resultando no caminho “/Volumes/workspace/bronze/arquivos_brutos/chocolate_sales.csv”. Dessa forma, foi possível a leitura do arquivo pelo notebook sem interferência de esquema, de modo que todos os campos ingressassem como texto e preservassem o formato original.



Estratégia de carga

O pipeline opera em modo de **carga completa (full load)**: cada execução relê integralmente o arquivo de origem e sobrescreve as tabelas de todas as camadas. A estratégia é adequada à natureza estática da fonte, um arquivo único que não recebe atualizações incrementais. Como consequência, o campo “data_ingestao” registra o momento da carga mais recente, e não o histórico de ingestões. Em um cenário com chegada

periódica de novos dados, a estratégia adequada seria a carga incremental, com acréscimo apenas dos registros inéditos e uso de “data_ingestao” para distinguir as levadas.

3. Modelagem e Catálogo de Dados

3.1. Modelo adotado

Considerando o objetivo do trabalho e a estrutura da base, identifica-se um fato central (a venda) cercado de dimensões descritivas (produto, vendedor, país e tempo). O modelo adotado foi, portanto, o **Esquema Estrela (Star Schema)**, estrutura clássica de Data Warehouse otimizada para consultas analíticas, materializada na camada Gold.

3.2. Estrutura das tabelas

Tabela fato – “workspace.gold.fato_vendas”

Grão: uma linha por venda registrada

Campo	Tipo	Descrição
sk_produto	bigint	Chave substituta do produto; relaciona-se a `dim_produto`
sk_vendedor	bigint	Chave substituta do vendedor; relaciona-se a `dim_vendedor`
sk_pais	bigint	Chave substituta do país; relaciona-se a `dim_pais`
data_venda	date	Data da venda; relaciona-se a `dim_tempo`
valor_venda	decimal(12,2)	Métrica. Valor total da venda
caixas_enviadas	int	Métrica. Quantidade de caixas expedidas

Dimensões

Tabela	Registros	Campos
dim_produto	22	sk_produto, nome_produto
dim_vendedor	25	sk_vendedor, nome_vendedor
dim_pais	6	sk_pais, nome_pais
dim_tempo	datas distintas	data, ano, mes, nome_mes, trimestre, dia_semana, flag_fim_semana

A dimensão tempo não provém dos dados de origem: foi construída a partir do intervalo de datas presente na base.

3.3. Chaves substitutas

As chaves substitutas foram geradas com `monotonically\_increasing\_id()`, que produz valores únicos crescentes com saltos. A implementação inicial utilizava `row\_number()` sobre uma janela ordenada, o que gerava chaves sequenciais, porém emitia aviso de performance do Spark (`No Partition Defined for Window operation`), pois uma janela sem particionamento obriga o motor a concentrar todos os dados em uma única partição. Com 1.094 registros isso é irrelevante, mas representaria gargalo em volumes maiores. Como chaves substitutas precisam apenas ser únicas e estáveis, e não sequenciais, a substituição não traz prejuízo ao modelo.

3.4. Catálogo de dados

O catálogo foi implementado nativamente no Unity Catalog, por meio de comentários aplicados a cada tabela e a cada coluna com “COMMENT ON TABLE” e “ALTER TABLE ... ALTER COLUMN ... COMMENT”. Para cada campo foram registrados: descrição do conteúdo, tipo de dado, domínio de valores e linhagem.

Catálogo de tabelas

table_schema	table_name	comment
bronze	vendas_raw	↕ Tabela com registros de vendas de chocolate ingeridos do arquivo chocolate_sales.csv (Kaggle, Chocolate Sales Data, licença MIT) sem qualquer transformação de conteúdo. Campos de origem mantidos como texto, preservando formatos originais e colunas de controle de ingestão acrescentadas. Grão: cada linha contém o registro de uma venda contida no arquivo de origem. Carga do tipo full load: cada execução relê o arquivo integralmente e sobrescreve a tabela; Total: 1.094 registros.
gold	dim_pais	Dimensão país. Grão: um registro por país distinto. 6 registros. Linhagem: valores distintos de workspace.silver.vendas_limpas.pais.
gold	dim_produto	↕ Dimensão produto. Grão: um registro por produto distinto do catálogo, 22 registros totais. Linhagem: valores distintos de workspace.silver.vendas_limpas.produto.
gold	dim_tempo	↕ Dimensão tempo. Grão: um registro por data distinta presente na base. Construída a partir do intervalo de datas de workspace.silver.vendas_limpas. Cobre o período de 2022-01-03 a 2022-08-31.
gold	dim_vendedor	↕ Dimensão vendedor. Grão: um registro por vendedor distinto. 25 registros totais. Linhagem: valores distintos de workspace.silver.vendas_limpas.nome_vendedor.
gold	fato_vendas	↕ Tabela fato do esquema estrela. Contém as métricas de negócio e as chaves substitutas para as dimensões produto, vendedor, país e tempo. Grão: uma linha por venda registrada. Linhagem: workspace.silver.vendas_limpas.
silver	vendas_limpas	↕ Camada Silver. Registros de vendas limpos, tipados e padronizados a partir de workspace.bronze.vendas_raw. Transformações aplicadas: remoção de símbolo monetário e separador de milhar, conversão de tipos, normalização de capitalização e remoção de espaços nas extremidades. Validação de conversão confirmou zero valores nulos nos três campos convertidos. Grão: cada linha contém o registro de uma venda contida no arquivo de origem. Total: 1.094 registros.

Catálogo de colunas

table_schema	table_name	column_name	data_type	comment
bronze	vendas_raw	Sales_Person	STRING	↕ Nome do vendedor responsável pela venda, como consta na origem. Formato: Texto. Renomeado de "Sales Person" por restrição do Delta Lake; 25 valores distintos observados.
bronze	vendas_raw	Country	STRING	↕ País onde a venda foi realizada, como consta na origem. Formato: Texto. Domínio observado: Australia, Canada, India, New Zealand, UK, USA.
bronze	vendas_raw	Product	STRING	↕ Nome do produto de chocolate vendido, como consta na origem. Formato: Texto. 22 valores distintos observados.
bronze	vendas_raw	Date	STRING	Data da venda em formato textual de origem (padrão dd-MMM-yy, ex.: 04-Jan-22).
bronze	vendas_raw	Amount	STRING	Valor total da venda em formato textual de origem, incluindo cifrão e separador de milhar.
bronze	vendas_raw	Boxes_Shipped	STRING	↕ Quantidade de caixas expedidas na venda, em formato textual de origem. Renomeado de "Boxes Shipped" por restrição do Delta Lake; Domínio: Inteiros positivos.
bronze	vendas_raw	data_ingestao	TIMESTAMP	↕ Metadado de controle: Timestamp da execução que gravou o registro. Registra o momento da ingestão mais recente e não o histórico de cargas, devido à carga full load. Gerado pelo pipeline.
bronze	vendas_raw	arquivo_origem	STRING	↕ Metadado de controle: Nome do arquivo de origem do registro. Valor fixo: chocolate_sales.csv. Gerado pelo pipeline para rastreabilidade de procedência.
gold	dim_pais	sk_pais	LONG	Chave substituta do país. Formato: Inteiro longo, único, não sequencial. Gerada pelo pipeline.
gold	dim_pais	nome_pais	STRING	↕ Nome do país onde a venda foi realizada. Formato: Texto. Domínio: Australia, Canada, India, New Zealand, UK, Usa.
gold	dim_produto	sk_produto	LONG	↕ Chave substituta do produto. Formato: Inteiro longo, único, não sequencial. Gerada pelo pipeline.
gold	dim_produto	nome_produto	STRING	Nome do produto de chocolate. Formato: Texto. Domínio: 22 valores distintos observados.
gold	dim_tempo	data	DATE	↕ Data de ocorrência da venda. Chave da dimensão. Formato: Data. Relaciona-se a fato_vendas.data_venda. Domínio: 2022-01-03 a 2022-08-31.

table_schema	table_name	column_name	data_type	comment
gold	dim_tempo	data	DATE	↕ Data de ocorrência da venda. Chave da dimensão. Formato: Data. Relaciona-se a fato_ven...
gold	dim_tempo	ano	INT	Ano da data. Formato: Inteiro. Domínio: 2022.
gold	dim_tempo	mes	INT	Número do mês. Formato: Inteiro. Domínio: 1 a 8.
gold	dim_tempo	nome_mes	STRING	↕ Nome do mês por extenso, em inglês. Formato: Texto. Domínio: January a August. Derivado de data.
gold	dim_tempo	trimestre	INT	Trimestre do ano. Formato: Inteiro. Domínio: 1 a 3.
gold	dim_tempo	dia_semana	STRING	↕ Dia da semana por extenso, em inglês. Formato: Texto. Domínio: Monday a Sunday. Derivado de data.
gold	dim_tempo	flag_fim_semana	BOOLEAN	↕ Indicador booleano de fim de semana. Verdadeiro para sábado e domingo, falso para os demais dias. Derivado de data.
gold	dim_vendedor	sk_vendedor	LONG	↕ Chave substituta do vendedor. Formato: Inteiro longo, único, não sequencial. Gerada pelo pipeline.
gold	dim_vendedor	nome_vendedor	STRING	Nome do vendedor. Formato: Texto. Domínio: 25 valores distintos observados.
gold	fato_vendas	sk_produto	LONG	↕ Chave substituta do produto. Formato: Inteiro longo. Relaciona-se a dim_produto.sk_produto. Gerada pelo pipeline; valores únicos e não sequenciais.
gold	fato_vendas	sk_vendedor	LONG	↕ Chave substituta do vendedor. Formato: Inteiro longo. Relaciona-se a dim_vendedor.sk_vendedor. Gerada pelo pipeline; valores únicos e não sequenciais.
gold	fato_vendas	sk_pais	LONG	↕ Chave substituta do país. Formato: Inteiro longo. Relaciona-se a dim_pais.sk_pais. Gerada pelo pipeline; valores únicos e não sequenciais.
gold	fato_vendas	data_venda	DATE	↕ Data da venda. Formato: Data. Relaciona-se a dim_tempo.data. Domínio: 2022-01-03 a 2022-08-31. Linhagem: Silver.data_venda, sem transformação adicional.
gold	fato_vendas	valor_venda	DECIMAL	↕ Valor total da venda. Formato: Decimal com duas casas. Domínio observado: valores positivos. Linhagem: Silver.valor_venda, sem transformação adicional.

table_schema	table_name	column_name	data_type	comment
gold	fato_vendas	valor_venda	DÉCIMAL	Valor total da venda. Formato: Decimal com duas casas. Domínio observado: valores positivos. Linhagem: Silver.valor_venda, sem transformação adicional.
gold	fato_vendas	caixas_enviadas	INT	Quantidade de caixas expedidas. Formato: Inteiro. Linhagem: Silver.caixas_enviadas, sem transformação adicional.
silver	vendas_limpas	nome_vendedor	STRING	Nome do vendedor responsável pela venda. Formato: Texto. Padronizado com remoção de espaços nas extremidades e capitalização inicial. Linhagem: Bronze.Sales_Person. 25 valores distintos.
silver	vendas_limpas	pais	STRING	País onde a venda foi realizada. Formato: Texto. Padronizado com remoção de espaços e capitalização inicial. Linhagem: Bronze.Country. Domínio: Australia, Canada, India, New Zealand, Uk, Usa.
silver	vendas_limpas	produto	STRING	Nome do produto de chocolate vendido. Formato: Texto. Aplicada apenas remoção de espaços nas extremidades, a capitalização original foi preservada. Linhagem: Bronze.Product. 22 valores distintos.
silver	vendas_limpas	data_ingestao	TIMESTAMP	Metadado de controle propagado da camada Bronze. Timestamp da carga mais recente.
silver	vendas_limpas	arquivo_origem	STRING	Metadado de controle propagado da camada Bronze. Nome do arquivo de origem.
silver	vendas_limpas	valor_venda	DÉCIMAL	Valor total da venda. Formato: Decimal com duas casas. Linhagem: convertido de Bronze.Amount mediante remoção de cifrão, separador de milhar e espaços. Domínio: Valores positivos.
silver	vendas_limpas	data_venda	DATE	Data em que a venda foi realizada. Formato: data. Linhagem: convertido de Bronze.Date (texto, padrão dd-MMM-yy). Domínio: Datas válidas. Conversão sem geração de nulos.
silver	vendas_limpas	caixas_enviadas	INT	Quantidade de caixas expedidas na venda. Formato: Inteiro. Linhagem: convertido de Bronze.Boxes_Shipped. Domínio: Inteiros positivos.

Exemplo overview no Catalog Explorer

dim_pais					
Overview Sample Data Details Permissions Policies History Lineage Insights Quality					
Description Dimensão país. Grão: um registro por país distinto. 6 registros. Linhagem: valores distintos de workspace.silver.vendas_limpas.pais.					
Filter columns...					
Column	Type	Popularity	Comment	Tags	Column masking
sk_pais	bigint	----	Chave substituta do país. Formato: Inteiro longo, único, não sequencial. Gerada pelo pipeline.		
nome_pais	string		Nome do país onde a venda foi realizada. Formato: Texto. Domínio: Australia, Canada, India, New Zealand, Uk, Usa.		

3.5. Critério adotado para registro de domínios

Cabe distinguir domínio, entendido como o conjunto de valores admissíveis de um campo, dos valores efetivamente observados em uma carga específica. Como a fonte é estática e o pipeline opera em carga completa, os dois conjuntos coincidem no estado atual, mas não são equivalentes por definição: uma carga futura poderia introduzir valores inéditos sem que houvesse restrição formal impedindo-o.

Adotou-se, portanto, o seguinte critério: campos categóricos de baixa cardinalidade e natureza conceitualmente fechada têm seus valores enumerados no comentário, sempre qualificados como observados na carga de referência; campos de cardinalidade elevada ou natureza mutável (como vendedor e produto) têm registrada apenas a cardinalidade, com remissão à respectiva tabela de dimensão. A escolha evita duplicar a informação de domínio em duas fontes que podem divergir ao longo do tempo, reconhecendo que, em um modelo dimensional, a própria tabela de dimensão constitui o registro autoritativo do domínio vigente.

4. Pipeline de Dados

4.1. Organização

Todo o pipeline foi implementado em um único notebook no Databricks, organizado em seções de markdown que delimitam cada camada. A opção por não ramificar em múltiplos notebooks deve-se ao escopo reduzido do fluxo (uma fonte, três camadas e cinco tabelas finais), cenário em que a fragmentação aumentaria a complexidade de orquestração sem benefício correspondente. O notebook executa integralmente de cima para baixo, reconstruindo todas as camadas a partir do arquivo de origem, o que garante reprodutibilidade.

O fluxo mapeia diretamente a Arquitetura Medalhão:

CSV (arquivo) → BRONZE (dado original) → SILVER (dado limpo e tipado) → GOLD (modelo dimensional)

4.2. Camada Bronze

Preserva o conteúdo exatamente como recebido. Todos os campos permanecem em formato textual e são acrescidos de dois metadados de controle: `data_ingestao` e `arquivo_origem`

As colunas “Sales Person” e “Boxes Shipped” foram renomeadas para “Sales_Person” e “Boxes_Shipped”, pois o Delta Lake não aceita espaços em nomes de coluna, mas nenhum valor foi alterado: a renomeação é exigência técnica do formato de armazenamento, não transformação de conteúdo.

4.3. Camada Silver

Concentra a limpeza e a padronização. Cada transformação e sua motivação:

Transformação	Motivo	Impacto
Remoção de cifrão, vírgula e espaços de Amount e conversão para decimal(12,2)	O campo chegou como texto; comparações numéricas e agregações são impossíveis sobre string	Viabiliza somas, médias e validação de domínio sobre a receita
Conversão de Date (texto “dd-MMM-yy”) para tipo date	Permitir ordenação cronológica, extração de componentes temporais e validação de intervalo	Viabiliza a construção da dimensão tempo
Conversão de Boxes_Shipped para int	Mesma razão dos anteriores	Viabiliza agregações de volume
trim e initcap em nome_vendedor e pais	Padronização preventiva contra variações de caixa e espaçamento	Nenhuma inconsistência foi corrigida, pois a origem já estava padronizada; a transformação protege cargas futuras
Apenas trim em produto	Nomes de produto possuem grafia própria; forçar capitalização a descaracterizaria	Preserva a grafia original
Tradução dos nomes de coluna para português	Legibilidade do modelo final	Nenhum impacto sobre os valores

A verificação pós-transformação confirmou zero nulos em `valor_venda`, `data_venda` e `caixas_enviadas`, atestando que os 1.094 registros atravessaram integralmente a tipagem.

4.4. Camada Gold

Construção das quatro dimensões por valores distintos, da dimensão tempo a partir do intervalo de datas, e da tabela fato por junção com as dimensões. Ao final da construção, foi verificado que a Gold preserva o conteúdo da Silver o que confirma que nenhuma junção duplicou linhas e nenhum registro se perdeu.

Teste de Integridade

```
▶ 18 hours ago (6s)

## testando resultados das transformações pra garantir integridade

print("Linhas na Silver:", df_silver.count())
print("Linhas na fato:", fato_vendas.count())

soma_silver = df_silver.agg({"valor_venda": "sum"}).first()[0]
soma_fato = fato_vendas.agg({"valor_venda": "sum"}).first()[0]
print("Receita Silver:", soma_silver)
print("Receita Fato: ", soma_fato)

> See performance (4)
```

Linhas na Silver: 1094
Linhas na fato: 1094
Receita Silver: 6183625.00
Receita Fato: 6183625.00

Tabelas no Catalog Explorer

The screenshot displays the 'Catalog Explorer' interface. On the left, a sidebar shows a tree view of the catalog structure. The 'workspace' is selected, showing a hierarchy of schemas: 'bronze', 'default', 'gold', and 'silver'. The 'silver' schema is expanded, showing a table named 'vendas_limpas'. The main panel on the right shows the 'workspace' overview, including a search bar for schemas, a list of schemas (bronze, default, gold, information_schema, silver), and a description section with an 'AI generate' button.

Catalog Explorer

Serverless Starter Warehouse Serverless 2XS

Catalog

Type to search

My organization

- workspace
 - bronze
 - Tables (1)
 - vendas_raw
 - Volumes (1)
 - default
 - gold
 - Tables (5)
 - dim_pais
 - dim_produto
 - dim_tempo
 - dim_vendedor
 - fato_vendas
 - information_schema
 - silver
 - Tables (1)
 - vendas_limpas

workspace

Overview Details Permissions Policies Workspaces

Description

AI generate Add


Filter schemas 5 schemas

Name

- bronze
- default
- gold
- information_schema
- silver


4.5 Linhagem

O Unity Catalog registra automaticamente a linhagem entre as tabelas e o notebook que as produziu, o que fornece a documentação de linhagem de forma diagramável.



The screenshot shows the 'fato_vendas' asset page in the Unity Catalog. The 'Lineage' tab is selected, displaying a table of upstream assets. The table has three columns: Name, Direction, and Type. Two assets are listed: 'vendas_limpas' (Table) and 'MVP - Engenharia de Dados' (Notebook), both with an 'Upstream' direction.

Name	Direction	Type
vendas_limpas workspace.silver	↑ Upstream	Table
MVP - Engenharia de Dados	↑ Upstream	Notebook



The screenshot shows the 'vendas_limpas' asset page in the Unity Catalog. The 'Lineage' tab is selected, displaying a table of upstream assets. The table has three columns: Name, Direction, and Type. Eight assets are listed, including 'fato_vendas' (Table) and 'MVP - Engenharia de Dados' (Notebook) as downstream assets, and several dimension tables and a raw table as upstream assets.

Name	Direction	Type
fato_vendas workspace.gold	↓ Downstream	Table
MVP - Engenharia de Dados	↓ Downstream	Notebook
dim_tempo workspace.gold	↓ Downstream	Table
dim_pais workspace.gold	↓ Downstream	Table
dim_vendedor workspace.gold	↓ Downstream	Table
dim_produto workspace.gold	↓ Downstream	Table
vendas_raw workspace.bronze	↑ Upstream	Table
MVP - Engenharia de Dados	↑ Upstream	Notebook

5. Qualidade de Dados

As checagens foram distribuídas entre as camadas conforme a natureza de cada critério. Na Bronze foram realizadas a contagem inicial de valores ausentes, a inspeção dos formatos textuais de origem e o levantamento dos domínios dos campos categóricos com comparação entre grafia bruta e normalizada. Na Silver foram executadas as verificações de consistência, unicidade, acurácia e outliers, que dependem de tipagem correta: comparações numéricas, validação de intervalos de data e cálculo de percentis não são aplicáveis sobre campos mantidos como texto.

Nenhum registro foi filtrado ou descartado entre as camadas como visto nos testes de integridade aplicados, de modo que a análise realizada sobre a camada intermediária é integralmente representativa do conteúdo ingerido.


5.1. Resultados dos testes de qualidade

Completeness: Não há valores nulos ou vazios em qualquer atributo, nem na origem nem após a tipagem.

Uniqueness: Não foram encontrados registros duplicados considerando a combinação de vendedor, produto, data e valor, mas foi identificada uma limitação da base: Como não há identificador único de transação, dois registros idênticos poderiam corresponder tanto a uma duplicata de carga quanto a duas vendas legitimamente iguais realizadas no mesmo dia e não seria possível distinguir os dois casos.

Consistency e accuracy: Datas entre 2022-01-03 e 2022-08-31, intervalo plausível e coerente. Zero valores não positivos em valor_venda e em caixas_enviadas. Como a conversão de datas não gerou nulos, conclui-se adicionalmente que nenhuma data de origem era inválida. Além disso, outra limitação da base foi identificada: cobertura temporal de apenas oito meses de um único ano civil, sem o quarto trimestre, período de maior demanda por chocolate nos mercados que compõem a base.

Outliers: Para avaliar valores extremos foi calculada a razão entre valor_venda e caixas_enviadas, denominada preco_medio_caixa, mas o comportamento dessa variável chamou atenção:



```
%sql
SELECT
  MIN(preco_medio_caixa) AS minimo,
  PERCENTILE(preco_medio_caixa, 0.25) AS q1,
  PERCENTILE(preco_medio_caixa, 0.50) AS mediana,
  PERCENTILE(preco_medio_caixa, 0.75) AS q3,
  MAX(preco_medio_caixa) AS maximo,
  AVG(preco_medio_caixa) AS media
FROM ( SELECT v.valor_venda / v.caixas_enviadas AS preco_medio_caixa
      FROM workspace.silver.vendas_limpas v)
```

	.00 minimo	1.2 q1	1.2 mediana	1.2 q3	.00 maximo	.00 media
1	0.0135135135135	14.5925632911392...	36.1418439716312...	79.160356619443...	4291.00000000000...	105.720204495395010...

A média (105,72) situa-se a quase três vezes a mediana (36,14), indicando forte assimetria à direita. O limite superior pelo critério de amplitude interquartil fica em torno de 176, e o máximo observado é 4.291,00, ou seja, mais de vinte vezes acima. O mínimo de 0,01 chama atenção no sentido oposto, motivando o estudo dos top 10 nos dois extremos.

Os extremos superiores correspondem a vendas de uma a sete caixas, em que a divisão inflaciona o valor unitário. Os extremos inferiores são comercialmente implausíveis: valores muito baixos para grandes quantidades de caixas. Observa-se ainda que produtos como 99% Dark & Pure, Choco Coated Almonds, Mint Chip Choco e Fruit & Nut Bars aparecem nos dois extremos, o que motivou investigar a amplitude de preço dentro de cada produto.

Investigação: ausência de relação funcional entre receita e volume

Amplitude muito maior que o esperado para os preços de todos os 22 produtos observados.

17 hours ago (2s) 65

```
%sql
SELECT v.produto,
       COUNT(*) AS vendas,
       MIN(v.valor_venda / v.caixas_enviadas) AS preco_min,
       ROUND(AVG(v.valor_venda / v.caixas_enviadas), 2) AS preco_medio,
       MAX(v.valor_venda / v.caixas_enviadas) AS preco_max
FROM workspace.silver.vendas_limpas v
GROUP BY v.produto
ORDER BY preco_max DESC;
```

> [See performance \(1\)](#)

	produto	vendas	preco_min	preco_medio	preco_max
1	White Choc	58	3.8450704225352	232.05	4291.000000000000...
2	Mint Chip Choco	45	0.3480662983425	161.58	3192.000000000000...
3	Eclairs	60	2.4640000000000	117.65	2326.33333333333...
4	Fruit & Nut Bars	50	0.5233644859813	107.15	2234.75000000000...
5	99% Dark & Pure	49	0.0833333333333	146.80	2097.66666666666...
6	Choco Coated Almon...	39	0.1349862258953	120.40	1576.16666666666...
7	Spicy Special Slims	54	1.0500000000000	119.89	1541.75000000000...
8	Organic Choco Syrup	52	1.5689655172414	91.18	1389.50000000000...
9	85% Dark Bars	50	0.6791044776119	103.13	1243.66666666666...
10	50% Dark Bites	60	1.5317286652079	111.75	1225.00000000000...

Correlação de Pearson praticamente nula

17 hours ago (3s)

```
%sql
SELECT ROUND(CORR(valor_venda, caixas_enviadas), 4) AS correlacao
FROM workspace.silver.vendas_limpas;
```

> [See performance \(1\)](#)

	correlacao
1	-0.0188

O resultado é incompatível com qualquer operação comercial: espera-se que a receita seja função do volume vendido, produzindo relação fortemente linear.

Gráfico de dispersão entre valor total da venda e quantidade de caixas, colorido por produto



O gráfico de dispersão confirma visualmente o achado. Os 1.094 registros distribuem-se homogeneamente pelo plano, sem tendência diagonal. A segmentação por produto afasta ainda a hipótese de que a nuvem resultasse da sobreposição de 22 relações lineares distintas, uma por produto: as cores aparecem uniformemente dispersas, sem que qualquer item ocupe faixa preferencial. A amplitude de receita permanece constante ao longo de todo o eixo de volume — vendas de cerca de 600 caixas alcançam os mesmos patamares que vendas de 50.

Problema detectado: valor_venda e caixas_enviadas foram gerados de forma independente na fonte.

Tratamento: a métrica derivada preco_medio_caixa, inicialmente prevista para a camada Gold, foi removida do modelo e utilizada apenas na etapa de teste de qualidade, para evidenciar o problema e documentar a análise feita. O fundamento é que a camada Gold se destina a dado pronto para consumo, e manter nela uma métrica comprovadamente destituída de significado induziria ao erro qualquer consumidor posterior.

Extensão da investigação às demais colunas

Constatada a independência entre dois campos que deveriam ser funcionalmente dependentes, não há razão para supor que o gerador da base tenha modelado as demais relações, por isso duas verificações adicionais foram desenhadas.

- Quantidade de vendas e de produtos distintos por vendedor

Foi possível identificar que cada vendedor comercializou entre 15 e 22 produtos distintos em 32 a 45 vendas, ou seja, a grande maioria dos vendedores trabalha com quase todo o catálogo de produtos. Não há carteira, especialidade ou concentração, que seria o esperado no contexto trabalhado, invés disso, o comportamento observado aponta para um sorteio independente a cada linha.

- Quantidade de vendas e receita média por país

Entre os seis países, a receita média por venda varia de 5.493,75 a 5.908,94, ou seja, uma faixa de apenas 7,5%, enquanto em operações reais, mercados distintos apresentam tíquetes médios distintos, por diferenças de poder de compra, mix de produto e canal de distribuição.

5.2. Síntese da avaliação de qualidade

Critério	Resultado
Completeness	Sem problemas — 100% em todos os atributos
Unicidade	Sem duplicatas; limitação por ausência de identificador de transação
Consistência	Sem problemas — formatos e intervalos válidos
Acurácia	Sem valores impossíveis nos campos individuais
Outliers	Assimetria extrema na razão entre receita e volume
Relação entre campos	Comprometida — campos gerados de forma independente

O conjunto de quatro evidências independentes — correlação nula, amplitude implausível por produto, ausência de especialização entre vendedores e uniformidade entre países — indica que os registros foram gerados por sorteio independente entre colunas, sem modelagem de estrutura conjunta. A base é, portanto, sintética ou fortemente artificial, apesar de sua descrição na plataforma de origem declarar agregação a partir de varejistas reais.

Reconhecimento de limitação de método: a inadequação da fonte foi detectada apenas na etapa de análise, com o pipeline já construído. Uma verificação exploratória na etapa da busca pelos dados, por exemplo o cálculo da correlação entre campos que deveriam ser dependentes, teria revelado o problema antes do investimento na modelagem.

6. Análise de Dados

6.1. Perguntas não respondidas

As perguntas 3 (variação de preço médio entre países) e 4 (se os vendedores de maior receita vendem volume ou produtos caros) dependem da métrica de preço unitário, invalidada na seção 5. Executá-las produziria números tecnicamente corretos e analiticamente vazios. Ambas foram mantidas no escopo original e classificadas como não respondidas, com a justificativa registrada.

As demais perguntas foram respondidas, ainda que as conclusões de negócio estejam comprometidas pela natureza da fonte. Há três razões para mantê-las: seus resultados integram o conjunto de evidências que sustenta o diagnóstico sobre a base; as consultas validam o modelo dimensional, evidenciando que as junções entre fato e dimensões produzem agregações corretas; e a discussão que as acompanha desloca-se do registro habitual, examinando o que a configuração dos números revela sobre a fonte que os produziu.

6.2. Pergunta 1 — Quais produtos geram maior receita e quais geram maior volume? São os mesmos?

Produtos ordenados por receita, com as posições em receita e em volume lado a lado

A ^B _C nome_produto	1 ² ₃ qtd_vendas	.00 receita_total	1 ² ₃ caixas_total	1 ² ₃ rank_receita	1 ² ₃ rank_volume
Smooth Sliky Salty	59	349692.00	8810	1	2
50% Dark Bites	60	341712.00	9792	2	1
White Choc	58	329147.00	8240	3	10
Peanut Butter Cubes	49	324842.00	8304	4	8
Eclairs	60	312445.00	8757	5	3
99% Dark & Pure	49	299796.00	8127	6	12
85% Dark Bars	50	299229.00	7793	7	14
Organic Choco Syrup	52	294700.00	7749	8	16
Spicy Special Slims	54	293454.00	8685	9	5
Mint Chip Choco	45	283969.00	8207	10	11
Almond Choco	48	277536.00	6736	11	21
Manuka Honey Choco	45	275541.00	7781	12	15
Milk Bars	49	269248.00	8330	13	7
Raspberry Choco	48	264740.00	7115	14	19
After Nines	50	261331.00	8257	15	9
Fruit & Nut Bars	50	259147.00	7738	16	17
Drinking Coco	56	256655.00	8660	17	6
Orange Choco	47	256144.00	7732	18	18
Baker's Choco Chips	41	249613.00	6998	19	20
Choco Coated Almonds	39	241486.00	6464	20	22
Caramel Stuffed Bars	43	231588.00	8717	21	4
70% Dark Bites	42	211610.00	8015	22	13

O produto de maior receita foi Smooth Sliky Salty (349.692,00); o de maior volume, 50% Dark Bites (9.792 caixas). A divergência entre os ordenamentos é acentuada e não sistemática: White Choc ocupa a 3ª posição em receita e a 10ª em volume; Caramel Stuffed Bars é 21º em receita e 4º em volume.

Em uma base real, essa divergência seria informativa, distinguindo produtos de alto valor agregado e baixo giro daqueles de volume. Aqui ela decorre de os dois rankings derivarem de sorteios independentes, e não é interpretável como característica de portfólio.

6.3. Pergunta 2 — Como a receita se distribui ao longo dos meses?

Receita, volume e quantidade de vendas agregados por mês

1 ² ₃ ano	1 ² ₃ mes	A ^B _C nome_mes	1 ² ₃ qtd_vendas	.00 receita_total	1 ² ₃ caixas_total
2022	1	January	154	896105.00	27535
2022	2	February	110	699377.00	18015
2022	3	March	131	749483.00	19561
2022	4	April	118	674051.00	21003
2022	5	May	135	752892.00	21856
2022	6	June	163	865144.00	26260
2022	7	July	149	803425.00	22876
2022	8	August	134	743148.00	19901

A receita mensal variou entre 674.051,00 (abril) e 896.105,00 (janeiro), amplitude de aproximadamente 33%, sem tendência de alta ou baixa ao longo da série e cabe notar que a ausência de relação entre a extensão do mês e o volume registrado reforça a leitura de flutuação aleatória, e não de efeito de calendário ou de demanda.

6.4. Pergunta 5 — Existe concentração de receita em poucos produtos ou vendedores?

Participação individual e acumulada de cada produto na receita total

^B _C nome_produto	.00 receita	.00 pct_receita	.00 pct_acumulado
Smooth Sliky Salty	349692.00	5.66	5.66
50% Dark Bites	341712.00	5.53	11.18
White Choc	329147.00	5.32	16.50
Peanut Butter Cubes	324842.00	5.25	21.76
Eclairs	312445.00	5.05	26.81
99% Dark & Pure	299796.00	4.85	31.66
85% Dark Bars	299229.00	4.84	36.50
Organic Choco Syrup	294700.00	4.77	41.26
Spicy Special Slims	293454.00	4.75	46.01
Mint Chip Choco	283969.00	4.59	50.60
Almond Choco	277536.00	4.49	55.09
Manuka Honey Choco	275541.00	4.46	59.55
Milk Bars	269248.00	4.35	63.90
Raspberry Choco	264740.00	4.28	68.18
After Nines	261331.00	4.23	72.41
Fruit & Nut Bars	259147.00	4.19	76.60
Drinking Coco	256655.00	4.15	80.75
Orange Choco	256144.00	4.14	84.89
Baker's Choco Chips	249613.00	4.04	88.93
Choco Coated Almonds	241486.00	3.91	92.83
Caramel Stuffed Bars	231588.00	3.75	96.58
70% Dark Bites	211610.00	3.42	100.00

Os seis produtos de maior receita (27% do catálogo) concentram 31,66% do faturamento. As duas proporções são praticamente equivalentes: cada produto contribui para a receita na mesma medida em que ocupa espaço no catálogo. Em uma operação real, seria esperado um comportamento assimétrico, com essa fatia do portfólio respondendo por algo próximo a 70% ou 80%.

As participações individuais decrescem suavemente de 5,66% a 4,23% entre o primeiro e o décimo quinto colocado, sem qualquer degrau que separe produtos líderes dos demais. Para referência, uma distribuição perfeitamente uniforme atribuiria 4,55% a cada um dos 22 produtos.

Participação na receita por país

^A _C nome_pais	.00 receita	.00 pct_receita	.00 pct_acumulado
Australia	1137367.00	18.39	18.39
Uk	1051792.00	17.01	35.40
India	1045800.00	16.91	52.31
Usa	1035349.00	16.74	69.06
Canada	962899.00	15.57	84.63
New Zealand	950418.00	15.37	100.00

Participação na receita por vendedor

^A _C nome_vendedor	.00 receita	.00 pct_receita	.00 pct_acumulado
Ches Bonnell	320901.00	5.19	5.19
Oby Sorrel	316645.00	5.12	10.31
Madelene Upcott	316099.00	5.11	15.42
Brien Boise	312816.00	5.06	20.48
Kelci Walkden	311710.00	5.04	25.52
Van Tuxwell	303149.00	4.90	30.42
Dennison Crosswaite	291669.00	4.72	35.14
Beverie Moffet	278922.00	4.51	39.65
Kaine Padly	266490.00	4.31	43.96
Marney O'breen	259742.00	4.20	48.16
Barr Faughny	258713.00	4.18	52.35
Roddy Speechley	251062.00	4.06	56.41
Gunar Cockshoot	238483.00	3.86	60.26
Gigi Bohling	232666.00	3.76	64.03
Karlen Mccaffrey	223895.00	3.62	67.65
Jehu Rudeforth	220976.00	3.57	71.22
Jan Morforth	219667.00	3.55	74.77
Curtice Advani	216461.00	3.50	78.27
Rafaelita Blaksland	210245.00	3.40	81.67
Husein Augar	205212.00	3.32	84.99
Andria Kimpton	201747.00	3.26	88.25
Mallorie Waber	200592.00	3.24	91.50
Camilla Castle	196616.00	3.18	94.68
Dotty Strutley	190624.00	3.08	97.76
Wilone O'kielt	138523.00	2.24	100.00

A referência de comparação é a participação que cada elemento teria caso a receita fosse distribuída de forma perfeitamente igualitária, ou seja, 16,67% para cada um dos seis países e 4,00% para cada um dos 25 vendedores. Entre os países, a participação observada variou de 15,37% a 18,39%, afastando-se em menos de dois pontos percentuais da referência. Entre os vendedores, o primeiro colocado alcançou 5,19%, pouco mais de um ponto acima da divisão igualitária.

Em nenhuma das três dimensões analisadas (produto, país ou vendedor) observou-se a concentração que caracteriza operações comerciais reais. O resultado é coerente com a conclusão de que os registros foram gerados por sorteio independente, sem modelagem de preferência de mercado.

6.5. Discussão geral

O objetivo inicial era entender o comportamento de vendas de uma operação de chocolates e para isso foi construído um pipeline funcional, no qual os dados percorrem as três camadas, a modelagem dimensional está consistente e o teste de integridade confirma preservação de registros e receita entre Silver e Gold.

O que a etapa de análise revelou, porém, é que a fonte escolhida não sustenta conclusões de negócio. Na verificação de qualidade foi possível identificar a ausência de relação funcional entre receita e quantidade, amplitude implausível de preço unitário por produto, distribuição praticamente uniforme entre países e ausência total de especialização entre vendedores. Dessa forma, o conjunto de evidências indica fortemente a geração sintética sem modelagem de estrutura conjunta entre as colunas, apesar de a documentação da fonte declarar agregação a partir de varejistas reais.

Finalmente, as perguntas formuladas não são respondíveis com esta fonte e seria necessário buscar outra base de dados antes investir em dashboards ou modelos sobre ela. Nesse caso, o valor do pipeline não está nas respostas que produziu, mas em ter permitido descobrir a inadequação da fonte de forma sistemática e documentada.

7. Autoavaliação

7.1. Objetivos atingidos

O pipeline foi construído de ponta a ponta e é reprodutível: o notebook executa integralmente, de cima para baixo, reconstruindo todas as camadas a partir do arquivo de origem. A Arquitetura Medalhão foi implementada com separação clara de responsabilidades entre Bronze, Silver e Gold, materializada em schemas distintos do Unity Catalog, e a progressão de dado bruto até dado modelado está evidenciada em cada etapa.

A modelagem dimensional em esquema estrela foi concluída, com tabela fato e quatro dimensões, e validada por teste de integridade de contagem e de totais. O catálogo de dados foi implementado nativamente na plataforma, contemplando descrição de contexto, tipo de dado, domínio de valores e linhagem para cada campo, com a linhagem entre camadas adicionalmente rastreável pelo recurso de lineage do Unity Catalog.

A verificação de qualidade cobriu os cinco critérios previstos e foi ela que produziu o principal resultado do trabalho.

7.2. Objetivos não atingidos

Duas das cinco perguntas não foram respondidas, por dependerem de uma métrica de preço unitário que a própria análise de qualidade demonstrou não possuir significado.

Mais amplamente, o objetivo de negócio declarado — entender o comportamento de vendas — não foi alcançado, já que a fonte não o sustenta.

7.3. Dificuldades encontradas

A primeira dificuldade foi de escopo: a intenção inicial era estudar o comportamento de vendas de bolos e doces no Rio de Janeiro, tema para o qual não existe base pública com preço, tipo, tamanho e localização de loja. O escopo foi redefinido para uma fonte disponível, decisão que precedeu todo o desenvolvimento.

No plano técnico, dois obstáculos exigiram investigação: a recusa do Delta Lake em gravar colunas com espaço no nome e o aviso de performance por janela sem particionamento na geração de chaves substitutas; ambos estão documentados na seção 4 e evidenciaram pontos importantes sobre o funcionamento do formato transacional.

A dificuldade de maior consequência, porém, foi conceitual: reconhecer que a fonte escolhida era inadequada quando o pipeline já estava construído, e decidir o que fazer diante disso. A opção foi não produzir conclusões de negócio sobre dados que não as sustentam.

7.4. Trabalhos futuros

O caminho natural é refazer o pipeline sobre uma fonte transacional real. A estrutura construída é largamente reaproveitável: mudariam apenas as transformações específicas da camada Silver, permanecendo válidos o desenho das camadas, o modelo dimensional e a estratégia de catalogação.

Acrescentaria verificações de qualidade automatizadas ao longo do fluxo, de modo que violações de expectativa interrompam a execução em vez de serem descobertas na análise final. Incluiria, na etapa de seleção da fonte, uma validação estatística prévia (checagem de baixo custo) que verifique se relações esperadas entre campos efetivamente se sustentam, evitando o retrabalho. E avaliaria a migração para carga incremental caso a fonte passasse a receber atualizações periódicas.